Neural SDE の多項式 SINDy 蒸留—LARRY 造血分化データでの検証

2026-10-07 実施 / 研究レポート

要旨. LARRY in vitro 造血分化データで scDiffEq の Neural SDE を学習し、その drift f_θ と diffusion 係数 G_θ を、定数・べき・交差項だけからなる多項式で SINDy (STLSQ) 蒸留した。50 次元 PCA の teacher では drift の近似が事前基準を満たさなかった。そこで別途学習した 5 次元 PCA の teacher では、2 次多項式で drift (validation NRMSE 0.43, 51 係数) と G (同 0.33, 61 係数) が局所的に近似できた。しかし得られた symbolic SDE を day 2 → day 6 の 4 日間積分すると **58.6% の軌道が数値的に破綻**した。分岐 (Monocyte / Neutrophil) の組成も保存されなかった。中心仮説「Neural SDE を teacher にすると安定な symbolic SDE が得られる」は、今回の条件では支持されなかった。

詳細な数値・監査ログは 実験報告、実行済み Notebook は notebooks/ にある。

---

1. 背景

1.1 LARRY: lineage tracing 付き single-cell データ

Weinreb et al. (Science, 2020) は、マウス骨髄の造血前駆細胞に lentiviral barcode を導入した。day 2 / 4 / 6 に scRNA-seq を行い、**同じ clone に由来する細胞を時点をまたいで対応付けられる**データ (LARRY) を作った。同じ細胞を繰り返し測定してはいない (測定は破壊的) ので、得られるのは時点ごとの snapshot 分布と clone barcode による state–fate の対応である。単一細胞の連続軌道は得られない。

1.2 scDiffEq (Vinyard et al., Nat. Mach. Intell. 2025 / bioRxiv 2023.12.06.570508)

scDiffEq は、PCA などの低次元状態 $x \in \mathbb{R}^d$ 上で細胞状態の時間発展を drift–diffusion 方程式

$$dX_t = f(X_t)\,dt + g(X_t)\,dW_t$$

で表し、f と g をそれぞれニューラルネットで表す (Neural SDE)。論文の式 (1)–(4) にあたる。オプションとして drift を scalar potential の勾配に制約できる (PRESCIENT と同じ Waddington landscape 型の仮定)。

$$f(x) = -\nabla_x \psi(x)$$

学習時は Euler–Maruyama 離散化

$$X_{t+\Delta t} = X_t + f(X_t)\,\Delta t + g(X_t)\,\Delta W_t, \qquad \Delta W_t \sim \mathcal{N}(0, \Delta t)$$

で初期時点の細胞を前向き積分する (`torchsde.sdeint`)。各観測時点 t で、予測分布 $\hat{\mu}_t$ と観測分布 μ_t を エントロピー正則化最適輸送で比較する。

$$\mathrm{OT}_\varepsilon(\alpha, \beta) = \min_{P \in \Pi(\alpha,\beta)} \langle P, C \rangle + \varepsilon\, \mathrm{KL}(P \,\|\, \alpha \otimes \beta)\,, \qquad C_{ij} = \tfrac{1}{2}\|x_i - y_j\|_2^2$$

自己輸送項を差し引いた Sinkhorn divergence

$$S_\varepsilon(\alpha, \beta) = \mathrm{OT}_\varepsilon(\alpha, \beta) - \tfrac{1}{2}\mathrm{OT}_\varepsilon(\alpha, \alpha) - \tfrac{1}{2}\mathrm{OT}_\varepsilon(\beta, \beta)$$

の時点和 $\mathcal{L}_S = \sum_{t > t_0} S_\varepsilon(\hat{\mu}_t, \mu_t)$ を損失とする (論文式 (5)–(13))。LARRY では 増殖/細胞死シグネチャ由来の growth weight を分布の重みに使う。

drift と diffusion の寄与比を

$$\rho(x) = \frac{\|f(x)\|_2}{\|g(x)\|_2}$$

と定義し、目標比 ρ^* からのずれを罰する正則化を加える。

$$\mathcal{L}_v = \lambda \frac{1}{N} \sum_{i=1}^{N} \big(\rho^* - \rho(x_i)\big)^2, \qquad \mathcal{L} = \mathcal{L}_S + \mathcal{L}_v$$

論文 (式 (14)–(16)) は LARRY の fate prediction benchmark で ρ^* を調べ、$\rho^* = 2.5$, $\lambda = 100$ を採用した。この設定で PRESCIENT、CellRank、Dynamo などより高い clonal fate bias 予測精度を報告している。本研究はこの学習済み Neural SDE を「teacher」として使う。

1.3 SINDy と stochastic SINDy

SINDy (Brunton, Proctor & Kutz, PNAS 2016) は、候補関数 library $\Theta(x) = [\theta_1(x), \dots, \theta_p(x)]$ を用意する。そのうえで力学系 $\dot{x} = f(x)$ を、疎な係数行列 Ξ を使って

$$f(x) \approx \Theta(x)\,\Xi$$

と表す。STLSQ (sequentially thresholded least squares) は ridge 回帰

$$\Xi = \arg\min_{\Xi} \; \|Y - \Theta(X)\Xi\|_F^2 + \alpha \|\Xi\|_F^2$$

を解き、$|\xi_{jk}| < \lambda$ の係数を 0 にして残りで再推定する、という操作を繰り返す。Boninsegna, Nüske & Clementi (J. Chem. Phys. 2018) はこれを SDE に拡張した。時系列の増分から Kramers–Moyal 型の条件付きモーメント

$$f(x) \approx \frac{\mathbb{E}[X_{t+\tau} - X_t \mid X_t = x]}{\tau}, \qquad D(x) = G(x)G(x)^\top \approx \frac{\mathbb{E}[(X_{t+\tau} - X_t)(X_{t+\tau} - X_t)^\top \mid X_t = x]}{\tau}$$

を推定し、それぞれを疎回帰する。ただし LARRY には同一細胞の増分がないので、この直接法はそのままでは適用できない (§4.5)。

1.4 本研究の問い

> 柔軟な Neural SDE を teacher にして $x \mapsto f_\theta(x)$, $x \mapsto G_\theta(x)$ を直接蒸留すれば、雑音の多い snapshot から直接 SINDy を行うよりも安定した symbolic SDE が得られるか。

---

2. データと teacher Neural SDE

項目	内容
データ	`sdq.datasets.larry()` 公式 loader。原本 130,887 cells × 2,492 genes
subset	公式 Quickstart 条件 (Monocyte / Neutrophil fate clone + Undifferentiated)。9,350 cells
状態	upstream PCA。50 PC (公式) と、別学習の 5 PC (探索的)
時点	day 2 / 4 / 6
環境	Python 3.11.17, PyTorch 2.6.0+cu124, scdiffeq 1.1.4, torchsde 0.2.6, PySINDy 2.1.0, RTX 2070
teacher 学習	seed 0, 1500 epochs, package 既定値 ($\rho^* = 2.5$, $\lambda = 100$, $\Delta t = 0.1$, lr 10^{-4}, μ: [512, 512], σ: [32, 32])

5-PC teacher は 50-PC teacher の射影ではなく、最初から別に学習したモデルである。5 PC は、training subset における 50-PC 状態分散の 59.57% を保持する (全遺伝子の explained variance ではない)。

2.1 runtime で確認した tensor の意味

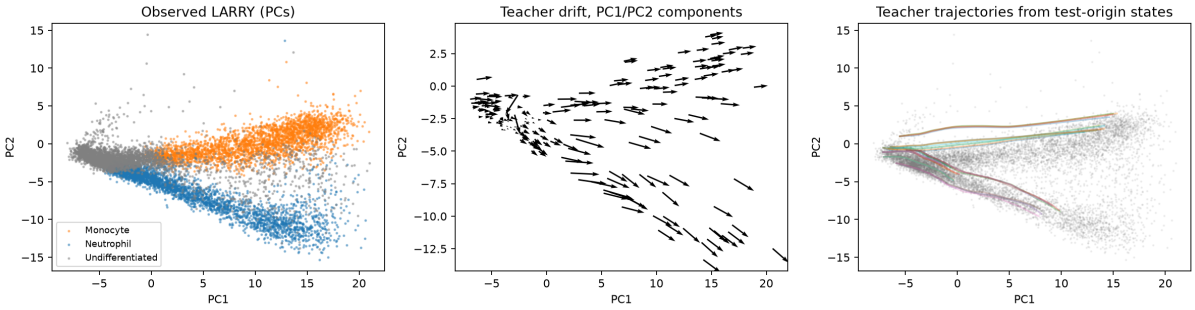
インストール済みの実装と runtime の shape を確かめた (model_semantics.md)。teacher は `LightningSDE_FixedPotential_RegularizedVelocityRatio` / `PotentialSDE` で、Itô 型、`noise_type="general"`、`brownian_dim=1`、時間に依存しない自律系である。

$$f_\theta(x) = c\,\nabla_x \mu_\theta(x)\ \ (c=1), \qquad G_\theta(x) \in \mathbb{R}^{d\times 1}, \qquad D_\theta(x) = G_\theta(x) G_\theta(x)^\top \in \mathbb{R}^{d\times d}$$

- $\mu_\theta : \mathbb{R}^d \to \mathbb{R}$ は scalar potential である。実装上の符号は $+\nabla$ だが、論文の $-\nabla\psi$ と同値 ($\psi = -\mu$)。
- Brownian motion は **1 本だけ**で、全 PC がそれを共有する。そのため D_θ は rank ≤ 1 の PSD 行列であり、「各 PC に独立なノイズが入る対角 diffusion」**ではない**。
- 単位は f が PC/day、G が PC/√day、D が PC²/day。
- `adata.obs["diffusion"]` は $\|G_\theta\|_2$ という scalar であって、G や D そのものではない。

teacher	学習時間 (s)	最終 train loss	最終 validation loss
50 PCs	1784	56.06	87.79
5 PCs	1770	19.31	22.30

(両者は状態空間が異なるため、loss の大小は比較できない。)



---

3. 方法: teacher 関数の直接多項式蒸留

3.1 教師データ

trajectory から微分を推定する方法は使わなかった。状態点 x_k において teacher を直接評価し、その値を教師にした。

$$y_k^{(f)} = f_\theta(x_k) \in \mathbb{R}^d, \qquad y_k^{(G)} = G_\theta(x_k) \in \mathbb{R}^{d\times 1} \cong \mathbb{R}^d$$

(G の値は brownian_dim = 1 なので d 次元ベクトルとみなせる。)

query 点 x_k には、観測細胞の状態と、training 由来の初期状態から teacher で simulate した状態の両方を使った。teacher から生成した軌道は teacher への問い合わせ点にすぎず、実データの量を増やすものではない。

3.2 split と leakage 対策

- clone 単位で分割した: train 6,137 / validation 1,451 / test 1,762 cells。
- 標準化、domain 半径、STLSQ のスケールはすべて training だけで推定した。
- 次数・閾値・ridge は validation だけで選んで固定し、そのあと test を 1 回だけ評価した。
- 注意点がある。teacher の公式 cell-level split には 292 clone の重複があり、upstream PCA も全細胞を見ている。したがって、ここでいう held-out は **symbolic fit に対して** held-out という意味であり、独立な生物学的検証ではない。

3.3 library (ユーザー指定: 多項式のみ)

training の平均・標準偏差で標準化した座標 $z_i = (\mathrm{PC}_i - m_i)/s_i$ を使い、総次数 p 以下の全単項式を library にした。

$$\Theta_p(z) = \left\{ \prod_{i=1}^{d} z_i^{a_i} \ : \ a_i \in \mathbb{Z}_{\geq 0},\ \sum_i a_i \leq p \right\}, \qquad |\Theta_p| = \binom{d+p}{p}$$

定数項は 1 つだけで、2 次には $z_i z_j$、3 次に拡張すると $z_i^2 z_j$ のような交差項も含まれる。三角関数・指数・対数は含めない。library の大きさは $d = 5$ で 6 / 21 項 ($p = 1, 2$)、$d = 50$ で 51 / 1,326 項になる。次数は degree 1 → 2 の順に試した。degree 2 で事前の局所近似基準を満たしたため、当初の実験では degree 3 は未実施とした。

3.4 STLSQ とモデル選択

各出力成分 k について

$$\hat{f}_k(z) = \sum_j \xi_{jk}\, \theta_j(z), \qquad \hat{G}_k(z) = \sum_j \eta_{jk}\, \theta_j(z)$$

を、§1.3 の STLSQ (列を training RMS で正規化したときの無次元閾値 $\lambda \in \{0.01, 0.05, 0.1\}$, ridge $\alpha \in \{1, 10, 100\}$) で推定した。初期の unbiased refit (ridge なしの再推定) は validation NRMSE 56.96 と破綻したため、ridge を残した。評価指標は

$$\mathrm{NRMSE} = \frac{\sqrt{\frac{1}{N}\sum_k \|\hat{y}_k - y_k\|_2^2}}{\sqrt{\frac{1}{N}\sum_k \|y_k\|_2^2}}$$

とした。選択規則は次のとおり: validation NRMSE が最良値の 1.1 倍以内で、かつ drift 基準 0.5 以下を満たす候補のうち、active 係数が最少のものを選ぶ。評価は training 状態ノルムの 99.5% 分位点で定めた局所領域 (半径 25.46) の中で行った。

diffusion については G を直接蒸留し、共分散を

$$\hat{D}(z) = \hat{G}(z)\hat{G}(z)^{\top}$$

として構成した。こうすると PSD と rank-1 構造は自動的に保たれる。

3.5 symbolic SDE の simulation と検証

$$dX_t = \hat{f}(z(X_t))\, dt + \hat{G}(z(X_t))\, dW_t, \qquad z(x) = S^{-1}(x - m), \quad S = \mathrm{diag}(s_1, \ldots, s_d), \quad W_t \in \mathbb{R}^1$$

ここで X_t は元の PC 座標、$z(X_t)$ は training の平均 m と標準偏差 s により標準化した多項式への入力である。$\hat{f}$ の出力は PC/day、$\hat{G}$ の出力は PC/$\sqrt{\text{day}}$ であり、標準化座標 $Z_t = z(X_t)$ 自身のドリフト・拡散係数ではない。

この symbolic SDE を Itô Euler 法 ($\Delta t = 0.05$ day) で積分した。初期状態は固定した day 2 観測細胞 32 個で、4 replicate × seed 3 つ (202 / 203 / 204) の計 384 軌道を、teacher と同じ条件で day 2 → 4 → 6 まで計算した。状態の clipping は行っていない。非有限値が出た軌道と、状態ノルムが domain 半径の 10 倍を超えた軌道を「数値的失敗」と数えた。day 6 の fate は、symbolic training の観測細胞だけで fit した KNN で読み出した (test 精度 0.9455)。

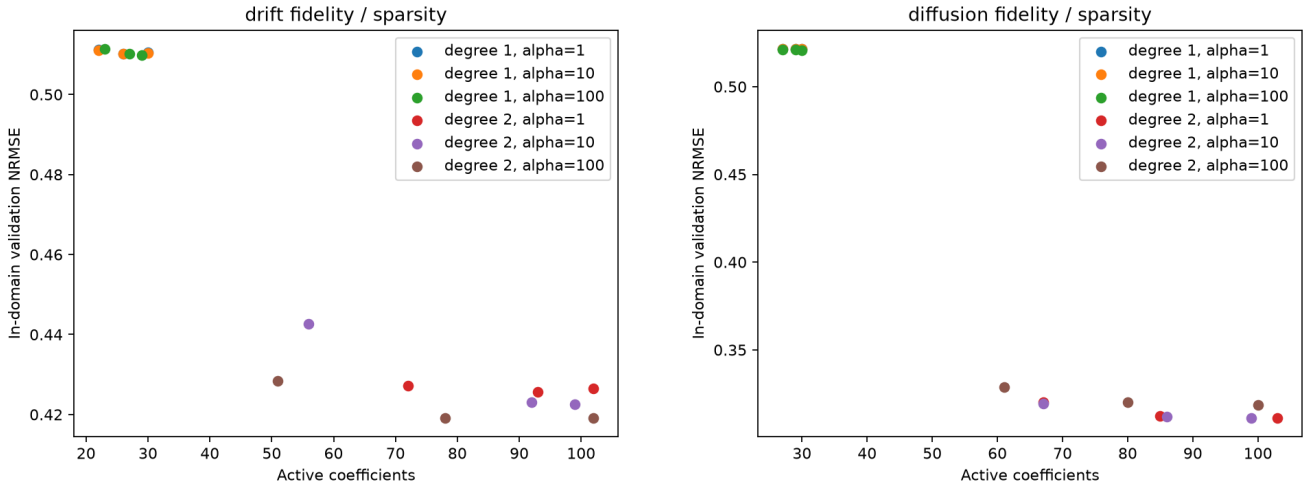
---

4. 結果

4.1 drift / G の蒸留精度

case	library 項数	active 係数	α / λ	validation NRMSE	test NRMSE	bootstrap 平均選択率
50-PC drift	1326	2815	100 / 0.05	0.554	0.659	0.731
5-PC drift	21	51	100 / 0.1	0.428	0.471	0.886
5-PC G	21	61	100 / 0.1	0.329	0.358	0.954

- **50-PC**: 局所領域の中でも NRMSE 0.554 で、事前基準 0.5 を満たさなかった。全領域では NRMSE が 9.07 に達し、外挿に非常に弱い。このゲートに従い、50-PC の diffusion 蒸留は行わなかった。
- **5-PC**: degree 1 の最良 validation NRMSE は drift 0.510 / G 0.521 だった。degree 2 にすると基準を満たしたため、degree 3 は試していない。
- 5-PC の安定性は次のとおり。clone 単位 bootstrap 5 回で、主要項は高い頻度で選ばれた。閾値を ±10% 動かしたときの support Jaccard は drift 0.944 / 0.789、G 0.984 / 0.903 だった。ただし bootstrap は 5 回だけなので、厳密な信頼区間ではない。



4.2 得られた式 (5-PC teacher の蒸留)

座標は training で標準化した PC である (係数は元の PC 座標での係数ではない)。

$$z_1 = \frac{\mathrm{PC}_1 - 3.278}{7.282}, \quad z_2 = \frac{\mathrm{PC}_2 + 2.702}{3.337}, \quad z_3 = \frac{\mathrm{PC}_3 - 0.536}{5.897}, \quad z_4 = \frac{\mathrm{PC}_4 + 1.367}{1.969}, \quad z_5 = \frac{\mathrm{PC}_5 - 1.272}{1.730}$$

係数は有効数字 3 桁に丸めて示す。全精度の値は drift 式 と G 式、または `model.json` にある。

drift $\hat{f}(z)$ [PC/day] (active 係数 6 + 6 + 10 + 12 + 17 = 51)

$$\begin{aligned}
\hat{f}_1 &= 6.22 + 2.05z_1 - 1.28z_2 - 1.07z_5 - 1.30z_1z_4 + 0.695z_1z_5 \\
\hat{f}_2 &= -1.22 - 0.506z_1 + 1.93z_3 + 0.372z_2^2 - 0.234z_2z_3 - 0.224z_3^2 \\
\hat{f}_3 &= -1.12 - 0.777z_1 + 1.57z_2 + 2.65z_3 - 0.455z_1z_2 - 0.307z_1z_3 - 0.367z_1z_4 \\
&\quad + 0.465z_1z_5 + 0.259z_2z_3 - 0.543z_4z_5 \\
\hat{f}_4 &= 1.50 + 1.81z_1 - 0.745z_2 - 1.61z_3 - 0.422z_4 - 1.16z_1^2 + 0.689z_1z_2 + 0.580z_1z_4 \\
&\quad - 0.327z_1z_5 + 0.278z_3^2 + 0.341z_3z_4 - 0.330z_4^2 \\
\hat{f}_5 &= -0.820 - 1.40z_1 + 0.305z_2 + 1.98z_3 - 0.335z_4 - 1.49z_5 + 0.783z_1^2 - 0.464z_1z_2 \\
&\quad - 0.418z_1z_4 + 0.668z_1z_5 + 0.200z_2z_3 + 0.363z_2z_4 - 0.510z_3^2 + 0.677z_3z_5 \\
&\quad + 0.240z_4^2 - 0.373z_4z_5 - 0.369z_5^2
\end{aligned}$$

diffusion 係数 $\hat{G}(z) \in \mathbb{R}^{5\times 1}$ [PC/√day] (active 係数 15 + 10 + 13 + 9 + 14 = 61, 単位 10^{-2})

$$
\begin{aligned}
10^2\hat{G}_1 &= 1.64 + 2.34z_2 + 2.34z_3 + 2.71z_4 - 1.73z_5 + 2.72z_1^2 - 2.27z_1z_2 + 2.46z_1z_5 \\
&\quad + 0.507z_2^2 + 0.914z_2z_4 - 2.73z_3^2 + 1.85z_3z_4 - 0.654z_3z_5 + 0.575z_4^2 - 0.929z_4z_5 \\
10^2\hat{G}_2 &= -8.34 - 5.84z_1 + 6.55z_2 + 6.75z_3 + 2.25z_1^2 - 1.37z_1z_2 - 1.47z_2z_3 \\
&\quad - 0.778z_3^2 + 2.16z_3z_5 + 1.46z_4^2 \\
10^2\hat{G}_3 &= 4.36 - 2.78z_1 + 8.80z_3 + 4.70z_4 - 1.82z_5 + 7.28z_1^2 - 4.34z_1z_2 - 4.77z_1z_4 \\
&\quad + 2.44z_1z_5 - 2.31z_2z_3 - 1.13z_3^2 - 1.95z_3z_4 - 1.20z_4z_5 \\
10^2\hat{G}_4 &= -4.85 - 8.94z_1 + 4.85z_2 + 6.26z_3 - 3.06z_1^2 + 2.49z_1z_2 - 0.960z_2^2 \\
&\quad + 3.03z_2z_3 - 0.797z_4z_5 \\
10^2\hat{G}_5 &= -4.88 - 3.09z_1 - 2.93z_2 + 6.71z_3 + 2.23z_5 - 1.04z_1^2 - 1.14z_1z_2 \\
&\quad - 1.67z_1z_3 + 1.19z_1z_4 - 1.53z_1z_5 - 1.22z_2z_3 - 0.590z_2z_5 + 0.777z_3^2 + 0.836z_3z_5
\end{aligned}
$$

ここから得られる symbolic SDE は

$$
dX_t = \hat{f}(z(X_t))\,dt + \hat{G}(z(X_t))\,dW_t, \qquad \hat{D}_X(x) = \hat{G}(z(x))\hat{G}(z(x))^\top
$$

である。成分ごとに書けば $\hat{D}_{X,kl}(x) = \hat{G}_k(z(x))\hat{G}_l(z(x))$ で、標準化入力 z について最大 4 次の多項式になる。$\hat{f}$ は個別の多項式として fit したもので、teacher のような勾配構造 $f = \nabla\mu$ を**強制していない** (勾配場なら元の PC 座標でヤコビアンが対称になるはずだが、標準化の中心 $z = 0$ において、例えば $\partial\hat{f}_1/\partial\mathrm{PC}_2 = -1.28/3.337 \approx -0.38$ に対して $\partial\hat{f}_2/\partial\mathrm{PC}_1 = -0.506/7.282 \approx -0.07$ であり、対称になっていない)。これらは PCA latent 座標上の teacher 近似式であり、**遺伝子制御の機構式ではない**。

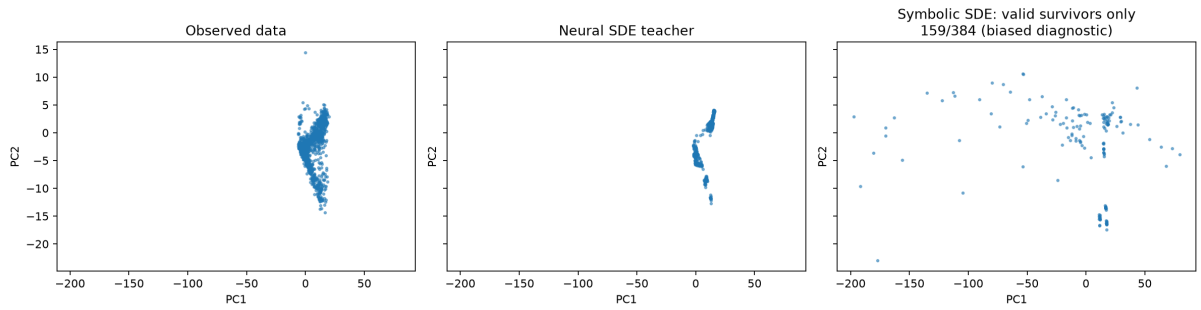
4.3 symbolic SDE の simulation: 負の結果

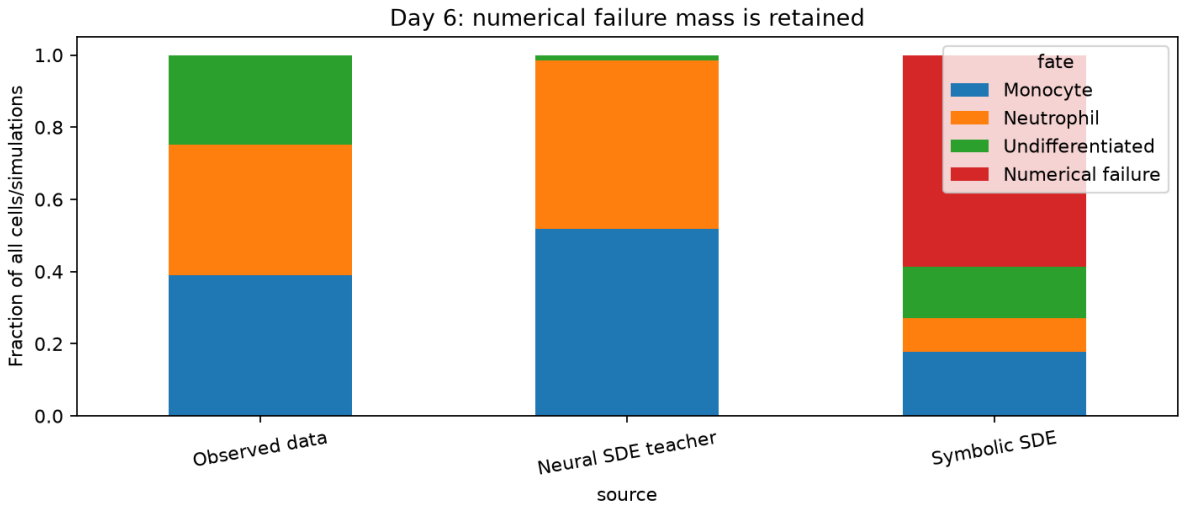
day 6 組成	観測データ	Neural SDE teacher	symbolic SDE
Monocyte	0.391	0.518	0.177
Neutrophil	0.362	0.466	0.094
Undifferentiated	0.247	0.016	0.143
数値的失敗	0	0	**0.586**

- day 6 時点で、symbolic SDE は 225/384 軌道 (58.6%) が破綻した。teacher は 0/384 だった。$\Delta t = 0.025$ でも非有限値が出たので、刻み幅だけの問題ではない (連続時間 SDE が数学的に爆発することの証明でもない)。
- 失敗した質量も含めた teacher–symbolic 間の fate 組成の total variation は 0.714 だった。
- 64 方向 sliced Wasserstein 距離 (標準化座標) は次のとおり。

	teacher ↔ observed	symbolic ↔ observed	symbolic ↔ teacher
day 4	0.253	1.070	1.068
day 6	0.377	評価不能 (非有限)	評価不能

- teacher 自体も観測組成とずれており、特に Undifferentiated が過少である。teacher と一致しても、それだけでは生物学的に正しいことにはならない。
- 局所的な関数誤差が小さく、PSD も保たれていたが、積分すると局所領域の外へ逸脱し、分布が崩れた。検証結果を見たあとに次数・閾値を再調整することはしていない。





4.4 マイルストーン判定

milestone	判定
M0 データ取得	達成
M1 Neural SDE 学習・評価・simulation	達成
M2 drift SINDy	50-PC は未達。5-PC は局所近似の基準を満たす
M3 symbolic SDE (diffusion 込みで安定に積分できる)	**未達** (G の式は得たが積分が不安定)
M4 分岐挙動の保存	**未達**

4.5 raw data からの直接 baseline

LARRY には単一細胞の増分がないため、§1.3 の Kramers–Moyal 推定はそのままでは使えない。代わりに限定的な proxy を作った。連続する 2 時点で観測された clone について、clone ごとの PC 重心 $\bar{x}_c(t)$ を求め、

$$y_c = \frac{\bar{x}_c(t+2) - \bar{x}_c(t)}{2\ \mathrm{day}} \approx \Theta(\bar{x}_c(t))\,\Xi$$

を同じ多項式 STLSQ で直接回帰した (train 310 / validation 75 / test 90 pairs)。この変位には分岐・増殖・サンプリングの影響が 混ざるため、diffusion は識別できないとして推定していない。

2 日間の重心変位 test NRMSE	50 PCs	5 PCs
raw 多項式 proxy	0.843	0.831
Neural SDE teacher	0.967	1.088
symbolic SDE	—(drift ゲート不通過)	1.197

この限定的な指標では raw proxy のほうが良かった。ただしこれは公正な stochastic-SINDy 比較ではなく、どちらかの優位性を示す証拠としては扱わない。

5. 考察と今後

1. **関数近似と力学の安定性は別物である.** NRMSE 0.3–0.4 の局所近似でも、データ外の領域で多項式が発散する方向をもつと、SDE の積分で軌道がそこへ流れ出てしまう。teacher の勾配構造 (potential) や散逸性を保つ制約が必要と考えられる。候補は、potential μ を多項式で蒸留して $\hat{f} = \nabla\hat{\mu}$ とする方法や、高次項に安定化の制約を課す方法である。
2. **次元と sparsity のトレードオフ.** 50 PC では 2 次 library が 1,326 項と大きく、疎にしても 2,815 係数が残って解釈できなかった。5 PC にすれば解釈できる大きさになったが、保持する分散は約 60% で、teacher も別物になる。
3. **teacher の誤差も蒸留される.** teacher 自体が day 6 の Undifferentiated を過少に予測しているため、teacher を忠実に再現しても実データへの適合は保証されない。
4. **次の実験.** teacher の学習と preprocessing を独立に分割し、training/validation だけで安定性・potential 構造を保つ 多項式表現を設計する。そのうえで、**今回まだ使っていない評価集合**で比較する。今回の test 結果を使った事後的な tuning は行わない。

---

6. 再現

```
python -m src.data            # LARRY 取得・subset
python -m src.baseline        # 50-PC teacher 学習 (--latent-dim 5 で 5-PC)
python -m src.prepare         # teacher query 点と split
python -m src.run_distillation --config configs/experiment_pc5.json
python -m src.validate        # symbolic SDE simulation と検証
python -m src.direct_baseline
python -m pytest -q           # 8 tests
```

5-PC の完全なコマンドと環境構築は notebooks/README.md にある。依存関係は requirements-lock.txt を参照。checkpoint と生データは容量が大きいため Git の管理外にあり、SHA256 と生成手順を docs/1007_results.md に記録した。式と `model.json` を使うだけなら checkpoint は不要である。

参考文献

- M. E. Vinyard et al. *Learning cell dynamics with neural differential equations.* Nat. Mach. Intell. 7, 1969–1984 (2025). doi:10.1038/s42256-025-01150-3 —preprint: *scDiffEq: drift-diffusion modeling of single-cell dynamics with neural stochastic differential equations.* bioRxiv doi:10.1101/2023.12.06.570508
- C. Weinreb, A. Rodriguez-Fraticelli, F. D. Camargo, A. M. Klein. *Lineage tracing on transcriptional landscapes links state to fate during differentiation.* Science 367, eaaw3381 (2020).
- S. L. Brunton, J. L. Proctor, J. N. Kutz. *Discovering governing equations from data by sparse identification of nonlinear dynamical systems.* PNAS 113, 3932–3937 (2016).
- L. Boninsegna, F. Nüske, C. Clementi. *Sparse learning of stochastic dynamical equations.* J. Chem. Phys. 148, 241723 (2018). doi:10.1063/1.5018409
- J. Feydy et al. *Interpolating between optimal transport and MMD using Sinkhorn divergences.* AISTATS (2019).

その他のリンクは source.md にまとめた。

エージェント向け

Codex / Claude は作業前に 1007_instruction.md、`.agents/rules/` のすべて、該当する `.agents/skills/`、source.md を読むこと。`AGENTS.md` と `CLAUDE.md` は入口ファイルであり、詳細なルールは `.agents/` にまとめている。